

Big Data e Computação em Nuvem

Introdução à Computação em Larga Escala

The logo for Inspêr, featuring the word "Inspêr" in a black serif font. The text is centered within a white rectangular area that has a red border on its top and left sides. The background of the slide features a vertical rainbow gradient on the right side.

Inspêr

Prof. Michel Fornaciali, PhD. – michelsf@insper.edu.br
Prof.^a Thanuci Silva, PhD. – thanucis@insper.edu.br

Agenda

- Apresentação da disciplina
- Introdução ao Big Data
- Necessidades de ferramentas sofisticadas para Ciência de Dados em larga escala

Contexto: aplicações atuais de Big Data Analytics

 Olhar Digital

Cientistas estudam uso de inteligência artificial para detectar câncer

... por meio de machine learning, a classificar os tecidos entre saudáveis e doentes. Durante a endoscopia, o sistema analisa a imagem da ...
há 2 semanas



 TechCrunch

Aidoc raises over \$66M for AI radiology analysis technology

Aidoc develops "decision support" software based on artificial intelligence. This ...

02/10/2019

EVENTOS

Forum CIO Club

LEROY MERLIN APOSTA EM BIG DATA PARA UMA NOVA JORNADA DO CONSUMIDOR

O foco é capturar o cliente 4.0 que é hiperconectado e está cada dia mais exigente

14/09/2019 - 07H05 - POR EPOCA NEGÓCIOS ONLINE

 GlobeNewswire

Artificial Intelligence in Diagnostic Market worth

Growth in this market is primarily driven by government initiatives and the adoption of AI-based technologies, rising demand for AI ...
há 1 dia

Inteligência Artificial revoluciona o varejo

A tecnologia da Microsoft contribui para que todos os elos da cadeia – da manufatura ao ponto de venda incluindo o cliente final – saiam ganhando mais

Nestlé usa inteligência artificial para monitorar a felicidade das vacas

A iniciativa faz parte do Projeto Cowsense, uma ação desenvolvida para o acompanhamento das fazendas produtoras de leite orgânico

 Analytics Insight

Impact of Data Science in Healthcare

Data Science helps in advancing healthcare facilities and processes. It helps boost productivity in diagnosis and treatment and enhances the ...
há 2 dias



Como as empresas estão utilizando o Big Data para melhorar os resultados

08/10/2019 - 08H18 - ATUALIZADA ÀS 08H37 - POR ESTADÃO CONTEÚDO

Inteligência artificial é testada para aliviar demanda da Justiça

STJ está trabalhando em dois projetos ligados à inteligência artificial

Importância de Big Data & Cloud Computing

g1 G1

IA e Big Data são essenciais nas pesquisas de novos fármacos

A tendência na pesquisa farmacêutica se concentra na seleção de alvos terapêuticos definidos, terapias e estratificação de pacientes a...

há 21 horas



TeleSintese

Dados sensíveis de governo agora só podem ficar em nuvem soberana

Provedores de serviços de nuvem contratados pelo governo deverão comprovar estabelecimento no Brasil para armazenar os dados sensíveis.



TI INSIDE Online

86% das empresas brasileiras usam computação em nuvem, aponta estudo com profissionais de todo o país

86% das empresas brasileiras usam computação em nuvem, aponta estudo com profissionais de todo o país · Principais descobertas do estudo:..



VEJA

Real Time Big Data: Paes lidera ao governo do RJ em todos os cenários

Flávio Bolsonaro e Cláudio Castro são favoritos ao Senado, indica pesquisa publicada nesta quinta-feira.

há 1 dia



Mapeando expectativas!



Como a disciplina se conecta com o curso?

	1.º TRIM	2.º TRIM	3.º TRIM	4.º TRIM		5.º TRIM	6.º TRIM
Trilha Computação	Computação para Ciência de Dados	Big Data e Computação em Nuvem	Data Science Deploy			Clínicas I-IV	Clínicas V-VIII
Trilha Data & Analytics	Aprendizagem Estatística de Máquina I	Aprendizagem Estatística de Máquina II	Prática Avançada de Data Science e Visualization	Financial Analytics	Marketing Analytics		
Trilha Negócios			Métodos de Design para Ciência de Dados				

E na era da IA (generativa)?


Como ficam as aplicações de Big Data? Preciso me preocupar com estas ferramentas?

- Não eh só pedir que a IA faz?
- Agentes não tratam os dados massivos também?

Precisamos de M U I T O S dados para criar modelos de IA!

Estes modelos não conhecem os SEUS dados!

Ciência de dados + Big Data



Objetivos de aprendizagem

Ao término da disciplina o aluno deverá ser capaz de:

- **Entender** o desafio e complexidade de tratar dados em **ambientes Big Data**
- **Criar soluções** para análise de grandes volumes de dados
- **Consultar** bases de dados utilizando **SQL**
- **Compreender** a importância e aspectos gerais de Cloud Computing

Nossa disciplina utilizará Python 3. Além disso, utilizaremos alguns conhecimentos básicos de Linux, RegEx e programação funcional.

Requisitos

Pré-requisitos:

- Python (pandas, numpy, etc.);
- Linux básico;
- Programação funcional básica;

Bibliotecas:

- Python & Anaconda
- Dask: <https://dask.org>
- PySpark: <https://spark.apache.org/> (versão 3)
- AWS SDK for Python (boto3): <https://aws.amazon.com/sdk-for-python/>
- AWS Command Line Interface (AWSCLI): <https://aws.amazon.com/cli/>

Conjugaremos uma dinâmica de aula-laboratório em todos os encontros

Dinâmica

Aulas:

- Construção conjunta do conhecimento;
- Solução de problemas reais em conjunto;
- Exercícios e discussões;


Laboratórios a cada aula:

- Dúvidas;
- Exercícios de fixação;
- Exercícios de extensão;
- Acompanhamento do projeto final;

Focaremos na nuvem Amazon Web Services (AWS) com a utilização do Apache Spark em Python.

Conteúdo Programático

- Big Data e computação em nuvem;
- Arquitetura, elementos e gestão de serviços em nuvem;
- Big Data e fundamentos de processamento e distribuído;
- Fundamentos do Apache Spark;
- Estruturas de dados do Apache Spark;
- Programação PySpark para Apache Spark e Spark SQL.



Todas as nuvens possuem como base sistema operacional Linux. Caso você queira instalar, utilize as seguintes recomendações.

Material Complementar

- Instalação local, completa, no seu computador:
 - Tutorial de como instalar Ubuntu sobre VirtualBox:
 - Win: <https://www.youtube.com/watch?v=zsqJhle7CXE&t=608s>
 - Mac: <https://www.youtube.com/watch?v=aJcc-xC6krE>
- O Windows 10 tem um subsistema Linux (WSL).
Permite você abrir um terminal simplificado, sem interface gráfica, suficiente para testar comandos:
 - <https://www.youtube.com/watch?v=Eb6rEpXSTpY>
- Cheat-sheet com comandos mais importantes Linux:
 - <https://www.linuxtrainingacademy.com/linux-commands-cheat-sheet/>

Nossa bibliografia básica é o livro do Aven. Utilizaremos ainda SQL e AWS.

Bibliografia

Bibliografia Básica:

- **Data Analytics with SPARK using Python.** Aven, J. 2018. Addison-Wesley.

Bibliografia Complementar:

- Amazon Web Services in Action. Wittig, M. Wittig, A. 2nd. Ed. 2019. Manning.
- Cloud Computing: Theory and Practice. Marinescu, D. 2nd. Ed. 2018. Morgan Kaufmann.
- Learning Spark. Lightning Fast Data Analysis. Karau, H. et. Al. 2015. O'Reilly
- Spark, The Definitive Guide. Big Data Processing Made Simple. Bill Chambers & Matei Zaharia. 2018. O'Reilly.

Dúvidas? 😊

Big Data e Computação em Nuvem

O que é um dado?

“ Dados não são dados

Dados não são dados. Ou seja, não caem do céu, prontos e perfeitos para quem os consome. São o resultado, por vezes, de longos processos de construção que envolvem várias decisões metodológicas. Além disso, o consumo dos dados não é imediato. Quem lê ou analisa os dados precisa também estar capacitado para compreendê-los. Mesmo pesquisadores experimentados podem cair nas diversas armadilhas que uma nova e desconhecida base de dados geralmente apresenta.

 *Guia brasileiro de análise de dados: armadilhas & soluções.* ENAP, 2021.

O que caracteriza o Big Data?

Os 5 V's do Big Data

- Volume
- Variedade
- Velocidade
- Veracidade
- Valor



Imagem reproduzida de: <https://bit.ly/3meRz5z>

Reflexões

- Quais são as dificuldades de se trabalhar com computação em larga escala?
 - Infra
 - Tempo
 - Dev / debug
 - Orquestração de operações
- Como poderemos contorná-las?
 - Particionar os dados
 - Escalabilidade de infra (elasticidade)
 - Tolerância à falha

Escalabilidade

- É a habilidade de um sistema lidar com o aumento da carga de processamento sem apresentar uma degradação significativa em seu desempenho
- Há duas formas de se obter a escalabilidade:
 - **Escalabilidade vertical – *scale-up***
 - Fazer upgrade na infra existente (+ memória, por exemplo)
 - **Escalabilidade horizontal – *scale-out***
 - Adicionar novas máquinas ao parque computacional
 - Distribuir os dados e o trabalho de processamento em diversas máquinas

Desafios de processar Big Data

- É fato que a capacidade dos discos aumentou muito nos últimos anos:
 - Um disco típico de 1990 poderia armazenar **1.370 MB** de dados
 - Exemplo: Seagate ST-41600n (foto)
 - Um SSD atual pode armazenar **2 TB** de dados
 - Exemplo: Seagate Barracuda 120 (foto)
- Todavia, a velocidade de transferência de dados não seguiu na mesma proporção
 - Em 1990, um disco tinha uma velocidade de transferência de **4,4 MB/s**
 - Um SSD atual possui uma velocidade de transferência de **500 MB/s**



Desafios de processar Big Data

- É fato que a capacidade dos discos aumentou muito nos últimos anos:
 - Um disco típico de 1990 poderia armazenar **1.370 MB** de dados
 - Exemplo: Seagate ST-41600n (foto)
 - Um SSD atual pode armazenar **2 TB** de dados
 - Exemplo: Seagate Barracuda 120 (foto)
- Todavia, a velocidade de transferência de dados não seguiu na mesma proporção
 - Em 1990, um disco tinha uma velocidade de transferência de **4,4 MB/s**
 - Um SSD atual possui uma velocidade de transferência de **500 MB/s**




- Em 1990, levaríamos **5 minutos** para ler todos os dados do disco.
- Atualmente, levamos **mais do que uma hora** para ler todos os dados do disco!

Como lidar com esse problema?

Paralelizar?

- Dividir os dados em blocos (*chunks*) armazenados em diferentes discos, que são **lidos em paralelo**




Desafios do Paralelismo

- Falha de hardware
 - Com mais discos, maior é a chance de falhas em hardware
 - Solução?
 - Fazer uso da **redundância**
 - Isto é, replicar os dados em vários discos
 - Esta é a proposta de sistemas de arquivos como o **Hadoop Distributed File System** (HDFS)
- Processar os dados de uma maneira distribuída
 - Este é um dos papeis do **Apache Spark**



Desafios do Paralelismo

Scale out – escalabilidade horizontal

- Podemos fazer uso de um **cluster** de máquinas
- Os dados são armazenados em um sistema de arquivos distribuído (e.g., HDFS)
- Cada arquivo é dividido em blocos de tamanho fixos
- Cada bloco é **replicado** em diversos nós do cluster



Cluster




Barroso, Clidaras, Holzle (2013)

Paralelismo ...

Speedup Lei de Amdahl

- Numa aplicação existe sempre uma parte que não pode ser paralelizada
- Seja **S** a parte do trabalho sequencial, **1-S** é a parte susceptível de ser paralelizada
- Mesmo que a parte paralela seja perfeitamente escalável, o aumento do desempenho (speedup) está limitado pela parte sequencial

n = número de processadores



$$\text{Speedup} = \frac{1}{S + \frac{(1 - S)}{n}}$$

Paralelismo ...

Speedup Lei de Amdahl

- Se 10% das operações de um código precisam ser feitas sequencialmente, então o speedup não pode ser maior do que 10, independente do número de processadores

$$S = \frac{1}{0.1 + \frac{0.9}{10}} \cong 5.3$$

$p = 10$ processors

$$S = \frac{1}{0.1 + \frac{0.9}{\infty}} = 10$$

$p = \infty$ processors





Imagem: Wikipedia

Big Data, Computação em Larga Escala, High Performance Computing

■ Gartner:


*Big Data faz referência ao grande volume, variedade e velocidade de dados que **demandam formas inovadoras e rentáveis de processamento da informação**, para melhor percepção e tomada de decisão.*




Big Data, Computação em Larga Escala, High Performance Computing

■ Gartner:

*Big Data faz referência ao grande volume, variedade e velocidade de dados que **demandam formas inovadoras e rentáveis de processamento da informação**, para melhor percepção e tomada de decisão.*




Big Data - Stack



Prática de hoje

Dask



Leia o paper que descreve o Dask em detalhes http://conference.scipy.org/proceedings/scipy2015/pdfs/matthew_rocklin.pdf

Insper

Obrigado!

