

Big Data e Computação em Nuvem

Avançando no uso do Dask

Revisão de Programação Funcional

Prof. Michel Fornaciali, PhD. – michelsf@insper.edu.br
Prof.^a Thanuci Silva, PhD. – thanucis@insper.edu.br

The logo for Inspere, featuring the word "Inspere" in a black serif font. The text is centered within a white rectangular area that has a red border on its top and left sides. The background of the slide features a vertical rainbow gradient bar on the right side.

Inspere

Agenda

- Dask
 - Funcionamento & Vantagens
 - Formas de uso
 - Exercícios
- Revisão de programação funcional
 - Relação com MapReduce
 - Exercícios

Dask

Agora que vimos uma visão geral da importância da programação paralela e distribuída para trabalhar com Big Data, vamos aprofundar o uso de bibliotecas de alto nível para esta tarefa. Vantagens:

- Manipulação Eficiente de Grandes Conjuntos de Dados
- Abstração de Paralelismo
- Compatibilidade com Ecossistema Python
- Escalabilidade
- Aplicabilidade em Ciência de Dados e Análise
- Preparação para o Mundo Profissional
- Variedade de Tarefas Suportadas
- Aprendizado Contínuo em Computação Paralela



Dask

Aplicações em diversos nichos:

Geoespacial

Finança

Astrofísica

Microbiologia


Ciência ambiental

...

Veja mais, em: <https://stories.dask.org/en/latest/>


Paralelismo com Dask

Guarda muita similaridade com o ambiente de cluster padrão (e Spark!)



Componentes do Dask

Como armazenar os dados | Como planejar a execução | Como executar



Componentes do Dask



Dask Array

Dask DataFrame

Dask Bag

Dask Delayed

Futures



Dask bags, muito similares às RDD do PySpark, são usados para paralelizar cálculos simples em dados não estruturados ou semiestruturados, como texto, logs, registros JSON ou objetos Python definidos pelo usuário.

Atividade prática

1. Conhecendo como trabalhar com *Futures*
2. Avançando no uso do *Dask DataFrame*



Programação Funcional

Programação funcional

Intuição do paradigma



Por que é relevante em Big Data?

- Dividir pra conquistar
- O código “leve” vai até o dado “pesado”



Obrigado!

