

Big Data e Computação em Nuvem

Acesso ao ambiente Spark

The logo for Inspere, featuring the word "Inspere" in a black serif font. The text is centered within a white rectangular area that has a red border on its top and left sides. The background of the slide features a vertical rainbow gradient on the right side.

Inspere

Prof. Michel Fornaciali, PhD. – michelsf@insper.edu.br
Prof.^a Thanuci Silva, PhD. – thanucis@insper.edu.br

Acesso

A partir da aula 04 em diante, usaremos um ambiente em nuvem exclusivo para programação em PySpark!

- **Link:** <https://cdiapads.datascience.insper.edu.br/user/pads/lab>
- **User:** pads
- **Senha:** cZB!76ej4*yE

Sim, todos compartilham o mesmo usuário! :O

Isso tem:

- *Vantagens:*
 - É fácil ver o código dos colegas ou dos profs
 - Muito bom para consultar algum comando que acabou perdendo
 - Instalação de bibliotecas: alguém instalou? Todos têm acesso!
- *Desvantagens:*
 - Apps Spark precisam ter nomes diferentes
 - É fácil quebrar o ambiente; é fácil tocar o terror 😊

Caixa de Entrada - Michel Silva F

PADSONL07_Au... - JupyterLab

Boletim de notas / BIG DATA E

cdiapads.datascience.insper.edu.br/user/pads/lab/tree/PADSONL07/aula 04/PADSONL07_Aula04_PráticasPy

Entrar

FileEditViewRunKernelTabsSettingsHelp

/ PADSONL07 /

Name	Modified
aula 04	7m ago
dados	14m ago
users	20m ago

Terminal 1PADSONL07_Aula04_Prática:Terminal 2

Python 3 (ipykernel)

Insper

Programa Avançado em Data Science e Decisão

Big Data e Computação em Nuvem

Prof. Michel Fornaciali

Prof. Thanuci Silva

Aula 04 - Práticas em Spark RDDs

Do que praticamos na aula passada para o que vamos praticar hoje:

Tabela comparativa entre a programação utilizando Dask e a programação usando Spark RDDs.

Característica	Dask
Modelo de Programação	APIs paralelas para arrays, dataframes e listas. Agendamento dinâmico e execução em tempo real. Baseado em RDDs imutáveis. Opera

Simple24Python 3 (ipykernel) | IdleMode: CommandLn 1, Col 1PADSONL07_Aula04_PráticasPySpark_ALUNO.ipynb1

Pesquisar

20°C

POR PTB

18:20

27/10/2025

Would you like to get notified about official Jupyter news?

Open privacy policyYesNo

Caixa de Entrada - Michel Silva F

(4) Chat | Fabricio Eduardo Rodr

JupyterHub

Conteúdo / BIG DATA E COMPU

← → ↻

cdiapads.datascience.insper.edu.br/hub/user/pads/lab/tree/

Entrar

jupyterhub

Home Token Admin

pads Logout

Server not running

Your server is not running. Would you like to start it?

Launch Server

Se precisar, só clicar e ser feliz!

Pesquisar

File Explorer

Firefox

Chrome

Teams

Calendar

Outlook

PowerPoint

19°C

19:00

27/10/2025

Ambiente em nuvem

Maior vantagem: **escalabilidade!**

- Máquina parruda em aula; Máquina modesta outros horários
- Vamos combinar horários e dimensionamento ao longo do tri

```
16] %%time
1min rdd5.takeOrdered(10, key=lambda x: -x[1])

CPU times: user 17.7 ms, sys: 3.58 ms, total: 21.3 ms
Wall time: 1min 11s
[('4723129', 779),
 ('4463359', 716),
 ('4740796', 678),
 ('4345262', 658),
 ('4558333', 654),
 ('4313124', 633),
 ('4683195', 631),
 ('4459600', 613),
 ('4683202', 605),
 ('3953566', 411)]
```

Colab: 2 cores

```
[33]: %%time
rdd5.takeOrdered(10, key=lambda x: -x[1])

[Stage 17:> (0 + 8) / 8]
CPU times: user 6.61 ms, sys: 2.27 ms, total: 8.87 ms
Wall time: 1.48 s

[33]: [('4723129', 779),
 ('4463359', 716),
 ('4740796', 678),
 ('4345262', 658),
 ('4558333', 654),
 ('4313124', 633),
 ('4683195', 631),
 ('4459600', 613),
 ('4683202', 605),
 ('3953566', 411)]
```

Ambiente: 16 cores

Obrigado!

