

Financial Analytics

Séries Temporais: Fundamentos e Modelagem SARIMA

Paloma Vaissman Uribe Julio Trecenti

Insper — PADS

2026

Objetivos do Curso

Ao final do curso você será capaz de:

- **Analisar** dados temporais — tendências, sazonalidades e ruídos em séries financeiras
- **Selecionar** métodos estatísticos adequados ao problema de decisão
- **Ajustar e interpretar** modelos ARIMA e SARIMA
- **Programar** análises em Python

Estrutura do Curso

Forecasting

1. Fundamentos de séries temporais (*esta aula!*)
2. Modelagem SARIMA / Prophet

 **Trabalho intermediário** — 50% da nota

Finance Applications

3. Fatos estilizados em finanças
4. Modelos de volatilidade
5. VaR, CAPM, Pair Trading, Carteira Ótima
6. Modelos multivariados
7. Apresentação de trabalhos

 **Trabalho final** — 50% da nota

Parte 1 — Fundamentos

- Processo estocástico, i.i.d.
- Autocorrelação (ACF)
- Estacionariedade
- Random walk e ruído branco

Parte 2 — Componentes e Decomposição

- Tabela de componentes
- Decomposição aditiva/multiplicativa
- Diferenciação sazonal e dummy Covid
- Teste ADF

Parte 3 — PACF e Modelos

- Autocorrelação Parcial (PACF)
- Modelos AR, MA, ARIMA, SARIMA
- Tabela de identificação ACF/PACF

Parte 4 — Modelagem na Prática

- Procedimento Box-Jenkins
- AutoARIMA (Hyndman-Khandakar)
- Previsão com intervalos de confiança



Parte 1 · Fundamentos

Processo estocástico, autocorrelação e estacionariedade

1 · Processo Estocástico & Série Temporal

Um **processo estocástico** é uma família de variáveis aleatórias indexadas pelo tempo:

$$X = \{X(t, \omega), t \in T, \omega \in \Omega\}$$



NOTA

Cada **trajetória** $X^{(i)}(t)$ é uma **realização** do processo.
A série temporal observada é **uma** dessas infinitas trajetórias possíveis.

2 · Breve revisão: Variável Aleatória

Uma **variável aleatória** é uma função que associa a cada elemento $\omega \in \Omega$ do espaço amostral um número real:

$$X : \Omega \rightarrow \mathbb{R}$$

NOTA




Exemplo: ao jogar um dado não viciado, $\Omega = \{1, 2, 3, 4, 5, 6\}$ e definimos X como o resultado obtido, tal que $P(X = k) = \frac{1}{6}$ para $k = 1, \dots, 6$.

Um **processo estocástico** é uma *sequência* de variáveis aleatórias — é exatamente o que ocorre ao jogar o dado 500 vezes e registrar os resultados consecutivos.

2 · Processo i.i.d.

Quando as VAs são **independentes** e possuem a **mesma distribuição de probabilidade**, o processo é chamado **i.i.d.**:

```
1 import numpy as np
2
3 n = 500
4
5 def dados(n, k):
6     # Simula n lançamentos de um dado de k faces
7     return np.random.randint(1, k + 1, size=n)
8
9 dados_gerados = dados(n, 6)
```



⚠️ AVISO

Observe que a **ACF está toda dentro do intervalo de confiança** — confirmando ausência de dependência temporal. Séries temporais reais **não** são i.i.d.: há **memória** entre os pontos!

3 · Autocorrelação — Carregando os Dados

Usaremos o **IBC-Br** (BCB — código 24363), proxy mensal do PIB brasileiro:

```
1 import pandas as pd
2 from python_bcb import sgs
3
4 # IBC-Br: Índice de Atividade Econômica do Banco Central
5 ibc = sgs.get({'ibc': 24363}, start='2003-01-01')
6 ibc = ibc.dropna()
7 ibc.index = pd.to_datetime(ibc.index)
8 ibc.index.freq = 'MS'
```

NOTA



O IBC-Br é calculado mensalmente pelo Banco Central e funciona como **proxy do PIB** antes da divulgação oficial pelo IBGE.

Instale com: `pip install python-bcb`

3 · ACF do IBC-Br

$$\rho_k = \text{Cor}(Y_t, Y_{t-k}) = \frac{\text{Cov}(Y_t, Y_{t-k})}{\text{Var}(Y_t)}$$

```
1 import matplotlib.pyplot as plt
2 from statsmodels.graphics.tsaplots import plot_acf
3
4 fig, axes = plt.subplots(1, 2, figsize=(12, 4))
5 axes[0].plot(ibc.index, ibc['ibc'], color='#E4002B')
6 axes[0].set_title('IBC-Br — Índice Mensal (BCB 24363)')
7 plot_acf(ibc['ibc'], ax=axes[1], lags=24, title='ACF — Nível', zero=False)
8 plt.tight_layout(); plt.show()
```



4 · Estacionariedade

Um processo é **fracamente estacionário** quando possui:

Propriedade	Condição
Média	Constante para todo t
Variância	Constante para todo t
Covariância	Função apenas da defasagem



DICA

A ACF do IBC-Br decaí muito lentamente — sinal claro de **não-estacionariedade** e presença de raiz unitária.

5 · Defasagem e Diferenciação

Defasagem: $y_{t-1}, y_{t-2}, \dots$ | **Diferenciação:** $\Delta y_t = y_t - y_{t-1}$

```
1 ibc['ibc_lag'] = ibc['ibc'].shift(periods=1)
2 ibc['ibc_diff'] = ibc['ibc'].diff(periods=1)
```

IBC-Br — Nível




IBC-Br — 1ª Diferença



6 · Passeio Aleatório (*Random Walk*)

$$y_t = y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma^2)$$


```
1 np.random.seed(42)
2 n = len(IBC)
3 epsilon = np.random.normal(0, 1, n)
4 rw = np.zeros(n); rw[0] = epsilon[0]
5 for i in range(1, n): rw[i] = rw[i-1] + epsilon[i]
```



7 · Ruído Branco & Sazonalidade

$$\text{Cov}(\varepsilon_t, \varepsilon_s) = 0, \forall t \neq s$$

```
1 ibc_diff_clean = ibc['ibc_diff'].dropna()
2 plot_acf(ibc_diff_clean, ax=axes[1], lags=24, title='ACF — 1ª Diferença', zero=False)
```



⚠️ AVISO

A 1ª diferença **ainda não é ruído branco** — pico significativo no **lag 12** evidencia **sazonalidade anual** remanescente. Isso motiva o modelo **SARIMA**!



Parte 2 · Componentes e Decomposição

Tendência, sazonalidade, ciclo, resíduo, decomposição e teste ADF

7 · Removendo a Sazonalidade + Dummy Covid

$$\Delta\Delta_{12}y_t = \Delta y_t - \Delta y_{t-12}$$

```
1 ibc['ibc_diff_seas'] = ibc['ibc_diff'].diff(12)
2
3 # Dummy Covid: meses mar/2020-ago/2020 como missing
4 covid_idx = ibc.index[ibc.index >= '2020-03-01'][:6]
5 ibc.loc[covid_idx, 'ibc_diff_seas'] = np.nan
```



7 · Por que o SARIMA é Necessário?

NOTA

Mesmo após $\Delta\Delta_{12}$, ainda vemos estrutura no lag 12 da ACF. Isso não é um erro — é um sinal importante sobre a série!

- Na prática, o IBC-Br tem **sazonalidade não-estável** — a amplitude das flutuações muda com o ciclo econômico (crise 2015-16, Covid, recuperação)
- A diferença sazonal remove a **raiz unitária sazonal**, mas não captura toda a estrutura de curto prazo nos lags sazonais
- Para isso, o SARIMA inclui termos **MA sazonais** (Q) e/ou **AR sazonais** (P) que capturam o resíduo remanescente no lag 12
- É exatamente esse diagnóstico que **motiva a Parte 2** desta aula!

DICA

O lag 12 residual é uma pista valiosa: sugere um termo **SMA(1)** no modelo SARIMA, ou seja, $Q = 1$ na notação $\text{SARIMA}(p, d, q)(P, D, Q)_{12}$

8 · Componentes de uma Série Temporal

Componente	O que é	Exemplo	Característica
Tendência	Movimento de longo prazo	PIB crescendo ao longo de décadas	Persistente, suave
Sazonalidade	Padrão em período fixo e conhecido	IBC-Br cai em jan (13º), sobe em dez	Período constante
Ciclo	Flutuações de período variável	Ciclos de expansão/recessão (3–10 anos)	Menos previsível
Resíduo	Variação após remover os demais	Choques imprevistos (Covid, greves)	Idealmente ruído branco

Modelo Aditivo: $Y_t = T_t + S_t + R_t$ **Modelo Multiplicativo:** $Y_t = T_t * S_t * R_t$


 DICA

Tendência vs. Ciclo: na prática são difíceis de separar — muitos métodos os tratam juntos como “tendência-ciclo”. A sazonalidade, por ter período fixo, é mais fácil de isolar.

Aditivo vs. Multiplicativo: se o “zigue-zague” sazonal **cresce com o nível** da série → use multiplicativo ($Y_t = T_t \times S_t \times R_t$). Na dúvida, aplique log e use aditivo.

8 · Decomposição do IBC-Br

```
1 from statsmodels.tsa.seasonal import seasonal_decompose
2
3 decomp = seasonal_decompose(IBC['IBC'], model='additive', period=12)
4 fig = decomp.plot()
5 fig.suptitle('Decomposição Aditiva - IBC-Br', y=1.01)
6 plt.tight_layout(); plt.show()
```




NOTA

A crise de **2015-16** aparece na tendência; o choque do **Covid** no resíduo.

10 · Teste ADF — Nível vs Estacionarizado

```
1 from statsmodels.tsa.stattools import adfuller
2
3 def rodar_adf(serie, nome):
4     k = int(np.floor((len(serie) - 1) ** (1/3)))
5     res = adfuller(serie, maxlag=k, autolag=None, regression='c')
6     print(f"ADF {nome}: stat={res[0]:.3f} | p-value={res[1]:.3f}")
7
8 rodar_adf(IBC['ibc'], 'IBC-Br - Nível')
9 rodar_adf(IBC['ibc_diff_seas'].dropna(), 'IBC-Br - Estacionarizado')
```



Parte 3 · PACF e Modelos

Autocorrelação parcial, modelos AR/MA/ARIMA e SARIMA

11 · Processo AR(p)

O valor de hoje depende dos p valores passados:

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \varepsilon_t$$

- **AR(1) com $\phi = 0.8$:** ACF decai exponencialmente, PACF corta no lag 1
- **Estacionariedade:** requer $|\phi_i| < 1$ (raízes fora do círculo unitário)
- **Intuição:** o IBC-Br de hoje depende fortemente do mês anterior

11 · Processo MA(q)

O valor de hoje depende dos q **choques passados**:

$$Y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

- **MA(1) com $\theta = 0.8$** : ACF corta no lag 1, PACF decai
- Sempre estacionário (independente dos θ_i)
- **Intuição**: um choque econômico hoje ainda afeta o próximo mês

9 · Autocorrelação Parcial (PACF)

A PACF mede a correlação entre Y_t e Y_{t-k} **após remover o efeito dos lags intermediários**:

$$\phi_{kk} = \text{Cor}(Y_t - \hat{Y}_t, Y_{t-k} - \hat{Y}_{t-k})$$

onde $\hat{Y}_t$ é a projeção de Y_t sobre $Y_{t-1}, \dots, Y_{t-k+1}$.

NOTA

Algoritmo de Levinson-Durbin:

- Lag 1: $\phi_{11} = \rho_1$
- Lag 2: $\phi_{22} = \frac{\rho_2 - \rho_1^2}{1 - \rho_1^2}$
- Lag k : recursão usando os coeficientes anteriores

9 · Como interpretar ACF e PACF?

Padrão	ACF	PACF	Modelo
ACF corta	Corte em q	Decaimento	$MA(q)$
PACF corta	Decaimento	Corte em p	$AR(p)$
Ambas decaem	Decaimento	Decaimento	$ARMA(p, q)$
ACF não decai	Lento	Pico lag 1	Não estacionário


 AVISO

Na prática, os padrões raramente são tão limpos! Use a tabela como **ponto de partida**, não diagnóstico definitivo. Critérios AICc são mais confiáveis.

9 · ACF e PACF — Padrões Teóricos



```
1 # AR(1), MA(1) e ARMA(1,1) simulados
2 from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
3
4 fig, axes = plt.subplots(3, 2, figsize=(12, 9))
5 for row, serie in enumerate([ar1, ma1, arma1]):
6     plot_acf(serie, ax=axes[row, 0], lags=20, zero=False)
7     plot_pacf(serie, ax=axes[row, 1], lags=20, zero=False)
8 plt.tight_layout(); plt.show()
```

Padrões Teóricos: ACF vs PACF por tipo de processo



9 • ACF e PACF do IBC-Br Estacionarizado

```
1 from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
2
3 serie_est = ibc['ibc_diff_seas'].dropna()
4
5 fig, axes = plt.subplots(1, 2, figsize=(12, 4))
6 plot_acf(serie_est, ax=axes[0], lags=24, title='ACF - IBC-Br Estacionarizado', zero=False)
7 plot_pacf(serie_est, ax=axes[1], lags=24, title='PACF - IBC-Br Estacionarizado', zero=False)
8 plt.tight_layout(); plt.show()
```



12 · O Modelo ARIMA(*p*, *d*, *q*)

Combina diferenciação com AR e MA:

$$\underbrace{(1 - \phi_1 B - \cdots - \phi_p B^p)}_{\text{AR}(p)} \underbrace{(1 - B)^d}_{\text{I}(d)} Y_t = c + \underbrace{(1 + \theta_1 B + \cdots + \theta_q B^q)}_{\text{MA}(q)} \varepsilon_t$$

Parâmetro	Significado	Como determinar
<i>p</i>	Ordem AR	PACF: corte em <i>p</i>
<i>d</i>	Nº de diferenças	Teste ADF
<i>q</i>	Ordem MA	ACF: corte em <i>q</i>

13 · SARIMA(p,d,q)(P,D,Q) $_s$

Extensão sazonal do ARIMA — dois “andares” de parâmetros:

$$\underbrace{(1 - \Phi_1 B^{12})}_{\text{SAR}} \underbrace{(1 - \phi_1 B)}_{\text{AR}} \underbrace{(1 - B^{12})^D (1 - B)^d}_{\text{Diferenças}} Y_t = \underbrace{(1 + \Theta_1 B^{12})}_{\text{SMA}} \underbrace{(1 + \theta_1 B)}_{\text{MA}} \varepsilon_t$$

❗ NOTA

Para o IBC-Br mensal: $s = 12$, $d = 1$, $D = 1$

O lag 12 residual na ACF sugere **SMA(1)** ou **SAR(1)** — por isso o SARIMA é necessário!

Parte 4 · Modelagem na Prática

AR, MA, ARIMA e a extensão sazonal

13 · Guia de Identificação SARIMA

O que observar	Onde olhar	Indica
Pico ACF no lag q	ACF não-sazonal	$MA(q)$
Pico PACF no lag p	PACF não-sazonal	$AR(p)$
Pico ACF no lag s	ACF sazonal	$SMA(Q)$
Pico PACF no lag s	PACF sazonal	$SAR(P)$
Ambas decaem nos lags sazonais	ACF e PACF	$SARMA(P,Q)$



DICA

Para o IBC-Br: ACF corta após lag 1 → **MA(1)**; pico residual no lag 12 → **SMA(1)**
Candidato inicial: **SARIMA(0,1,1)(0,1,1)₁₂**

14 · Procedimento Box-Jenkins

- 1. Identificação** — Plotar a série, ACF, PACF. Determinar d, D pelos testes ADF/KPSS. Identificar p, q, P, Q pela tabela ACF/PACF.
- 2. Estimação** — Ajustar o modelo por máxima verossimilhança. Comparar candidatos via **AICc** (menor = melhor).
- 3. Diagnóstico** — Verificar se os resíduos são ruído branco: ACF dos resíduos, teste Ljung-Box. Se não: voltar ao passo 1.
- 4. Previsão** — Gerar previsões com intervalos de confiança.

15 · AutoARIMA — Seleção Automática

O algoritmo **Hyndman-Khandakar** automatiza o Box-Jenkins:

```
1 from statsforecast import StatsForecast
2 from statsforecast.models import AutoARIMA
3
4 sf = StatsForecast(
5     models=[AutoARIMA(season_length=12)],
6     freq='MS',
7     n_jobs=1,
8 )
9
10 # Prepara dados no formato Nixtla
11 ibcbr_df = ibc.reset_index()
12 ibcbr_df.columns = ['ds', 'y']
13 ibcbr_df['unique_id'] = 'ibcbr'
14
15 sf.fit(df=ibcbr_df)
16 previsao = sf.predict(h=12, level=[80, 95])
17 print(previsao.head())
```


15 · Como funciona o AutoARIMA

1. Testa estacionariedade → determina d e D automaticamente
2. Parte de um modelo inicial simples (ex: ARIMA(2,1,2))
3. Compara modelos vizinhos variando p, q, P, Q em ± 1
4. Seleciona o modelo com menor **AICc**
5. Verifica diagnóstico dos resíduos




DICA

O AutoARIMA **não substitui** o entendimento do processo — use-o como validação da sua escolha manual, não como ponto de partida cego.

15 · Previsão SARIMA no IBC-Br

```
1 previsao = sf.predict(h=12, level=[80, 95])
2
3 fig, ax = plt.subplots(figsize=(12, 4))
4 ax.plot(ibc.index[-48:], ibc['ibc'].values[-48:],
5         color='#E4002B', label='IBC-Br histórico')
6 ax.plot(previsao['ds'], previsao['AutoARIMA'],
7         color='#2ecc71', linestyle='--', label='Previsão 12m')
8 ax.fill_between(previsao['ds'],
9                previsao['AutoARIMA-lo-95'], previsao['AutoARIMA-hi-95'],
10               alpha=0.12, color='#2ecc71', label='IC 95%')
11 ax.legend(); plt.tight_layout(); plt.show()
```



Exercício Proposto

1. Carregue uma série temporal de interesse via `python_bcb`
2. Plote a série, ACF e PACF — identifique os componentes
3. Aplique as diferenças necessárias para estacionarizar
4. Use a tabela ACF/PACF para propor um modelo SARIMA
5. Compare com o AutoARIMA — o resultado é semelhante?
6. Verifique os resíduos: são ruído branco?

Referências Recomendadas

Forecasting: Principles and Practice (3ª ed.)

Hyndman & Athanasopoulos ·  otexts.com/fpp3

Material do Curso

 padsinsper.github.io/202632-fa

Dúvidas?

Financial Analytics · PADS · Insper · 2026