


Tópicos de Interpretabilidade

Angélica Custódio

Objetivos de Aprendizagem:

- Identificar a diferença entre modelos opacos e modelos interpretáveis;
- Entender os desafios e a importância da interpretabilidade em modelos de machine learning;
- Entender conceitos básicos de interpretabilidade;
- Explorar métodos globais de interpretabilidade, como PDP (Partial Dependence Plot);
- Explorar métodos locais de interpretabilidade, como LIME (Local Interpretable Model-agnostic Explanations) e SHAP (SHapley Additive exPlanations);
- Ser capaz de aplicar técnicas de interpretabilidade em modelos de regressão e classificação.

Exemplo: Aluguel de Imóveis em São Paulo



Qual modelo é melhor?

Interpretabilidade




Problemas da Falta de Interpretabilidade

- Decisões e Relações Não Explicáveis
- Viéses e Discriminação


Vieses são julgamentos, crenças e estereótipos sobre grupos de pessoas que são reproduzidos de forma automática e, no geral, socialmente sustentados pelas culturas dominantes. Podem ser associações não intencionais e não conscientes aprendidas através de experiências passadas.

TYPES OF UNCONSCIOUS BIAS



Understanding Unconscious Bias


Efeitos "Colaterais"



[Link vídeo](#)

Problemas da Falta de Interpretabilidade

- Viéses de Gênero



We had to scroll down the page to before this picture of Barbie appears

Google Image search for CEO has Barbie as first female result

Dada a repercussão gerada, esse viés do algoritmo recebeu intervenção, no entanto ainda há ressalvas ([reportagem da universidade de washington - Google's 'CEO' image search gender bias hasn't really been fixed](#))

Problemas da Falta de Interpretabilidade

- Viéses de Gênero

Outro caso conhecido é o do [algoritmo da Amazon](#) para automatização no recrutamento de funcionários.

Posições de **desenvolvimento de software e outros cargos técnicos tinham um grande viés de gênero**. Os algoritmos foram treinados a partir de dados históricos com viés de gênero, conseqüentemente, os currículos de mulheres eram penalizados.



Amazon desiste de ferramenta secreta de recrutamento que mostrou viés contra mulheres

Problemas da Falta de Interpretabilidade

- Viés Racial

O algoritmo COMPAS foi desenvolvido e usado nos EUA para identificar o risco de reincidência criminal de réus, a fim de apontar se elas poderiam ou não ser liberadas/pagar fiança;

Prediction Fails Differently for Black Defendants		
	WHITE	AFRICAN AMERICAN
Labeled Higher Risk, But Didn't Re-Offend	23.5%	44.9%
Labeled Lower Risk, Yet Did Re-Offend	47.7%	28.0%

Overall, Northpointe's assessment tool correctly predicts recidivism 61 percent of the time. But blacks are almost twice as likely as whites to be labeled a higher risk but not actually re-offend. It makes the opposite mistake among whites: They are much more likely than blacks to be labeled lower risk but go on to commit other crimes. (Source: ProPublica analysis of data from Broward County, Fla.)

[Erro por raça - propublica.org](https://www.propublica.org/article/compas-racial-bias)

Embora o algoritmo não usasse a variável de raça diretamente no processo de decisão, ele aprendeu a partir de dados criminais, cuja realidade é por si só racista nos EUA (Harvard: Criminal Justice), além de variáveis relacionadas a raça (emprego, escolaridade, etc).

Quais ferramentas podemos utilizar para prevenir isso?


Ferramentas de Interpretabilidade

Global:

- Vip
- PDP, ICE, ALE


Local:

- LIME
- Shapvalues




PDP

- Modelo Agnóstico;
- Efeito marginal de uma ou duas características;



PDP



LIME

- Ajuste de modelos mais simples, a partir das variáveis utilizadas no modelo e de sua predição, para explicar predições específicas.

Computer Science > Machine Learning

[Submitted on 16 Feb 2016 (v1), last revised 9 Aug 2016 (this version, v3)]

"Why Should I Trust You?": Explaining the Predictions of Any Classifier

Marco Tulio Ribeiro, Sameer Singh, Carlos Guestrin

Despite widespread adoption, machine learning models remain mostly black boxes. Understanding the reasons behind predictions is, however, quite important in assessing trust, which is fundamental if one plans to take action based on a prediction, or when choosing whether to deploy a new model. Such understanding also provides insights into the model, which can be used to transform an untrustworthy model or prediction into a trustworthy one. In this work, we propose LIME, a novel explanation technique that explains the predictions of any classifier in an interpretable and faithful manner, by learning an interpretable model locally around the prediction. We also propose a method to explain models by presenting representative individual predictions and their explanations in a non-redundant way, framing the task as a submodular optimization problem. We demonstrate the flexibility of these methods by explaining different models for text (e.g. random forests) and image classification (e.g. neural networks). We show the utility of explanations via novel experiments, both simulated and with human subjects, on various scenarios that require trust: deciding if one should trust a prediction, choosing between models, improving an untrustworthy classifier, and identifying why a classifier should not be trusted.

Subjects: **Machine Learning** (cs.LG); Artificial Intelligence (cs.AI); Machine Learning (stat.ML)

Cite as: [arXiv:1602.04938](https://arxiv.org/abs/1602.04938) [cs.LG]

(or [arXiv:1602.04938v3](https://arxiv.org/abs/1602.04938v3) [cs.LG] for this version)

LIME

Local + Interpretável + Explicação independente do modelo

LIME




Figura do Livro: [Explanatory Model Analysis](#)

- Queremos entender a relação das variáveis de um modelo de caixa preta, em torno de uma única instância de interesse.
- Para entender o comportamento local do modelo complexo em torno do ponto de interesse, geramos um conjunto de dados artificial, ao qual ajustamos um modelo interpretável.

LIME

Desafio: encontrar um modelo que se aproxime localmente de um modelo de caixa preta $f()$ em torno da instância de interesse x .

Considere G a classe de modelos interpretáveis. Para encontrar a aproximação necessária, minimizamos uma "função de perda":

$$g'(x) = \operatorname{argmin}_{g \in G} L(f, g, \pi_x) + \Omega(g).$$

onde:


O modelo $g()$ pertence à classe G ,

π_x define a vizinhança de x ,

$L()$ é uma função que mede a discrepância entre os modelos $f()$ e $g()$ em π_x ,

$\Omega(g)$ é uma penalização para a complexidade do modelo $g()$. A penalidade é usada para favorecer modelos mais simples de G .

LIME



LIME

Exemplo de Aplicação




Figura do Blog: [The Blue AI](#)

LIME

Exemplo de Aplicação - Titanic

Do livro [Explanatory Model Analysis](#), Johnny D é um garoto de 8 anos.

A probabilidade dele sobreviver é igual a 0.77.

```
johnny_d <- data.frame(  
  class = factor("1st", levels = c("1st", "2nd", "3rd",  
    "deck crew", "engineering crew",  
    "restaurant staff", "victualling crew")),  
  gender = factor("male", levels = c("female", "male")),  
  age = 8, sibsp = 0, parch = 0, fare = 72,  
  embarked = factor("Southampton", levels = c("Belfast",  
    "Cherbourg", "Queenstown", "Southampton")))
```

LIME

Exemplo de Aplicação - Titanic




Figura do Livro: [Explanatory Model Analysis](#)

Shapley Values

- Método de Teoria de Jogos;
- Propõe uma solução de distribuição justa de ganhos e custos para vários jogadores que trabalham cooperativamente;
- Se aplica quando as contribuições de cada jogador são desiguais, mas trabalham com o mesmo objetivo.

RAND > Published Research > Papers >

A Value for N-Person Games

by [Lloyd S. Shapley](#)

Related Topics: [Game Theory](#), [Mathematics](#)



Citation



Embed



An examination of a number of elementary properties of a value for the essential case. This value is deduced from a set of three axioms, having simple intuitive interpretations.

Shapley Values

Qual a conexão entre essa solução de Teoria de Jogos e a interpretabilidade de ML?



- O jogo é a tarefa de predição para uma única observação do conjunto de dados;
- O ganho é a diferença entre a predição real para a observação e a previsão média para todas as demais observações;
- Os jogadores são os valores das variáveis para a observação selecionada, que colaboram para receber o ganho, ou seja, prever um determinado valor.

Shapley Values

Para estimar os valores Shapley, primeiro selecionamos uma unidade observacional x do *dataset*, depois para cada variável j do modelo calculamos seu valor Shapley, definindo um número de iterações M .

Para realizar o cálculo, precisamos definir:

- número de iterações M ,
- unidade observacional x ,
- índice da variável j ,
- matriz de dados X ,
- modelo de aprendizado de máquina f .

Shapley Values

Os passos para o cálculo do valor Shapley da j -ésima variável são:

- Para todos $\mathbf{m} = 1, \dots, \mathbf{M}$:

Passo 1: Sorteie um exemplo aleatório $\mathbf{z}$ da matriz de dados $\mathbf{X}$

Passo 2: Escolha uma permutação aleatória das variáveis de $\mathbf{z}$

Passo 3: Ordene as variáveis em x : $\mathbf{x}_0 = (\mathbf{x}_1, \dots, \mathbf{x}_j, \dots, \mathbf{x}_p)$

Passo 4: Construa duas novas observações:


Passo 4.1: com a variável j : $x_{+j} = (x_1, \dots, x_{j-1}, x_j, z_{j+1}, \dots, z_p)$

Passo 4.2: sem a variável j : $x_{-j} = (x_1, \dots, x_{j-1}, z_j, z_{j+1}, \dots, z_p)$

Passo 5: Calcule a contribuição marginal

Passo 6: Calcule os valores Shapley como a média


Shapley Values



Shapley Values

Exemplo de Aplicação - Titanic

Se lembram do Johnny D.?



Foram consideradas 10 iterações!

Para saber mais/Referências

- Podcast Pizza de Dados - [Reconhecimento Facial e ética, com participação da Nina da Hora](#)

Livros:

- [Algoritmos, MYNEWS EXPLICA!, de Nina da Hora](#)
- [Algoritmos de Destruição em Massa, de Cath O'Neil](#)
- [Explanatory Model Analysis, de Przemyslaw Biecek e Tomasz Burzykowski](#)
- [Interpretable Machine Learning - A Guide for Making Black Box Models Explainable, do Christoph Molnar](#)
- [Interpretable ML with python, do Serg Masís](#)

Vamos para o R!